

Lab02

Davi Caldas de Godoi - 223555

```
library(dplyr)
```

Warning: pacote 'dplyr' foi compilado no R versão 4.5.3

Anexando pacote: 'dplyr'

Os seguintes objetos são mascarados por 'package:stats':

`filter`, `lag`

Os seguintes objetos são mascarados por 'package:base':

`intersect`, `setdiff`, `setequal`, `union`

```
library(readr)
```

Warning: pacote 'readr' foi compilado no R versão 4.5.3

```
library(ggplot2)
```

Warning: pacote 'ggplot2' foi compilado no R versão 4.5.3

```
library(remotes)
```

Warning: pacote 'remotes' foi compilado no R versão 4.5.3

```
library(ggcal)
```

1. Estatísticas Suficientes

Temos duas estatísticas suficientes para a determinação do percentual global de vôos atrasados, são elas:

- O número de vôos atrasados com 10 minutos ou mais ($\text{ARRIVAL_DELAY} > 10$)
- O número de vôos total que ocorreram dentro do grupo de análise.

Ambas as estatísticas serão representadas como variáveis: “n_atraso” e “n_total” sequencialmente.

2. Função getStats

```
getStats <- function(input, pos) {input %>%  
  filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%  
  filter(!is.na(MONTH), !is.na(DAY), !is.na(ARRIVAL_DELAY)) %>%  
  group_by(MONTH, DAY, AIRLINE) %>%  
  summarise(  
    n_atrasados = sum(ARRIVAL_DELAY > 10),  
    n_total = n(), .groups = "drop")}
```

3. ReadR e importação do CSV

```
col_types <- cols_only(  
  MONTH = col_integer(),  
  DAY = col_integer(),  
  AIRLINE = col_character(),  
  ARRIVAL_DELAY = col_double())  
  
estatisticas <- read_csv_chunked(  
  file = "flights.csv.zip",  
  callback = DataFrameCallback$new(getStats),  
  chunk_size = 100000,  
  col_types = col_types)
```


4. Compute Stats

```
computeStats <- function(dataf) {  
  dataf %>% group_by(MONTH, DAY, AIRLINE) %>%  
    summarise(  
      total_atrasados = sum(n_atrasados),  
      total_voos = sum(n_total),  
      .groups = "drop") %>%  
  transmute(  
    Cia = AIRLINE,  
    Data = as.Date(paste(2015, MONTH, DAY, sep = "-")),  
    Perc = total_atrasados / total_voos)}  
  
estatisticas_finais <- computeStats(estatisticas)
```

5. Mapa de Calor


```
pal <- scale_fill_gradient(  
  low = "#00BFFF",  
  high = "#B22222",  
  name = "Atraso em %")  
baseCalendario <- function(stats, cia) {  
  dados_cia <- stats %>%  
    filter(Cia == cia)  
  ggcal(dados_cia$Data, dados_cia$Perc)}  
  
cAA <- baseCalendario(estatisticas_finais, "AA")  
cDL <- baseCalendario(estatisticas_finais, "DL")  
cUA <- baseCalendario(estatisticas_finais, "UA")  
cUS <- baseCalendario(estatisticas_finais, "US")  
  
cAA + pal + ggtitle("Percentual de Atrasos em 2015 - AA")
```

Percentual de Atrasos em 2015 – AA




```
cDL + pal + ggtitle("Percentual de Atrasos em 2015 - DL")
```

Percentual de Atrasos em 2015 – DL




```
cUA + pal + ggtitle("Percentual de Atrasos em 2015 - UA")
```

Percentual de Atrasos em 2015 – UA



```
cUS + pal + ggtitle("Percentual de Atrasos em 2015 - US")
```

Percentual de Atrasos em 2015 – US



```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-24 14:03:04 -03"
```